

COMPTE RENDU - SYSTEME RAG FILMS

Décisions de conception:

- Modèle d'embedding : paraphrase-multilingual-mpnet-base-v2. Choisi pour sa capacité multilingue : les synopsis sont en anglais mais les questions peuvent être posées en français. Même modèle utilisé à l'indexation et à interrogation.
- Texte à embedder: titre + genres + synopsis. Genres extraits du JSON via `json.loads()`. Note, date et durée conservée en métadonnées (affichage uniquement).
- Pas de chunking: un film = un vecteur. Le synopsis étant une unité courte et indivisible, le fragmenter dégradait la qualité de la recherche.
- Index FAISS: IndexFlatIP + normalisation L2 = similarité cosinus. Sauvegardé avec `faiss.write_index()` et rechargé sans réindexation à chaque session.
- LLM : llama-3.3-70b-versatile via Groq, `temperature=0.7`.
Prompt système : ne recommander que les films du contexte, citer titre et note, signaler les films absents de la base.
- Filtre par langue (tous / fr / en) avec fallback automatique sur 50 films si moins de 2 résultats.
- Score de confiance (Bonus B): avertissement affiché si le meilleur score FAISS < 0.45.

Difficultés rencontrées

- Normalisation manquante : résultats aléatoires car `faiss.normalize_L2()` n'était pas appliqué sur le vecteur question. Corrigé en normalisant systématiquement avant la recherche.
- Indices décalés après filtrage : le DataFrame n'était pas réinitialisé, causant Film 4, Film 8... au lieu de Film 1, Film 2. Corrigé avec `reset_index(drop=True)` et `enumerate()` dans la boucle.

Conclusion

Le système final répond aux objectifs du TP : pipeline

RAG complet , persistance de l'index, boucle interactive, citation des sources et gestion des cas limites. Les choix techniques ont tous été motivés par des tests concrets sur le dataset.

AWOUTE AMEYO GRACE

DIABAGATE NA-MAMAN SARAN